

面向骨架动作识别的生成式对抗攻击

吴志泽^{1,2}, 邹焕鑫¹, 鹿梦浩¹, 华善聪¹, 李腾³, 王晓峰^{1,*}

(1. 合肥大学 人工智能与大数据学院, 安徽合肥 230601; 2. 安徽大学 光电信息获取与防护技术全国重点实验室, 安徽合肥 230601; 3. 安徽大学 人工智能学院, 安徽合肥 230601)

摘 要: 随着骨架动作识别技术的广泛应用, 其在对抗攻击下的鲁棒性问题日益凸显。为评估和揭示这一不足, 现有研究主要依赖对抗算法生成对抗样本, 以检验模型的稳健性。然而, 此类方法计算成本较高, 难以高效生成大规模、高质量的对抗样本。相比之下, 基于生成器的攻击方法在训练完成后, 可快速、高效地产生对抗样本, 具备更高的实用性。然而, 目前骨架对抗攻击的生成器大多采用对抗网络进行训练, 而对抗网络的收敛问题始终是一个难题, 限制了其实用性和稳定性。为此提出了一种无判别器的生成式骨架对抗攻击方法, 摒弃了对抗网络的判别器组件, 以生成隐匿性更强的对抗样本。该方法引入骨架流形约束和偏移损失函数, 以确保生成的对抗样本既符合人体运动规律, 又具备对抗性。实验结果表明, 所提方法在多种预训练模型上均表现出优异的攻击性能, 同时在感知性评估中保持较高的隐匿性。相较于现有对抗攻击方法, 该方法在攻击成功率、计算效率及不可感知性方面均展现出明显优势, 为骨架动作识别的安全性提供了一种新的有效手段。

关 键 词: 对抗样本; 无判别器的生成模型; 人体骨架点约束; 偏移损失函数; 生成式对抗攻击

中图分类号: V19; TP391.41

文献标识码: A

近年来, 基于人体骨架的行为动作识别技术已经取得了显著的进展, 并在多个领域得到了广泛的应用, 如自动驾驶、监控安防和人机交互等[1][2]。然而, 这些应用往往直接关系到公共安全与用户隐私, 一旦遭受对抗攻击而出现误识别, 可能引发严重后果[3]。例如, 攻击者可通过精心设计的对抗样本使安防系统无法正确识别可疑行为, 或让自动驾驶系统错误判断行人动作, 从而造成安全事故[4][5]。因此, 从应用安全的角度出发, 研究骨架动作识别模型在对抗攻击下的脆弱性具有重要意义。相较于图像领域已经有较为成熟的对抗攻击[6][7]与防御研究[8][9], 骨架动作识别的对抗研究仍处于起步阶段, 尤其是生成式攻击方法相关成果稀缺。这导致现有骨架识别系统缺乏系统性的安全评估手段, 模型的鲁棒性与可靠性无法得到充分验证。事实上, 攻击研究不仅仅是为了攻击本身, 更重要的是通过揭示模型的脆弱性, 推动更强健的防御机制与更可

靠的模型设计[10][11]。因此, 加强对骨架动作识别对抗攻击的研究, 尤其是生成式方法的探索, 对于提升系统的整体安全性和应用可信度具有不可替代的价值。

目前, 主流的攻击可以大致分为黑盒攻击与白盒攻击。其中经典的黑盒攻击有 BASAR[12], 白盒攻击有 SMART[3], CIASA[14]等。本文研究的攻击属于白盒攻击范畴。现有的白盒攻击主要依赖于算法生成对抗样本, 这类方法通过迭代优化样本, 以最大其对模型的误导性, 然而通常需要大量的查询次数来调整对抗样本, 从而提升攻击效果。相比之下, 基于生成器的对抗攻击虽然具有潜在的高效性和快速生成能力, 但相关研究较为有限, 尚未得到充分的探索。特别是基于 GAN 的攻击方法, 尽管能够在训练过后无查询或少查询的情况下生成对抗样本, 但在实际应用中常常面临生成器与判别器之间平衡的挑战, 导致训练不稳定或生成样本质量

收稿日期: 2025-09-25; 录用日期: 2025-12-19;

基金项目: 国家自然科学基金(62406095); 安徽自然科学基金(2308085MF213); 安徽省高校科学研究创新团队(2022AH010095, 2024AH010030); 合肥市揭榜挂帅(2023SGJ011); 光电信息获取与防护技术全国重点实验室开放课题(OEIAPT202503)

*通信作者: E-mail: xfwang@hfu.edu.cn

难以保证。因此如何设计更稳定、高效的基于生成器的对抗攻击方法,仍是当前研究有待解决的重要问题[15]。

为了解决这一问题,本文提出了一种无需判别器参与的生成器训练方法。该方法摒弃了传统生成对抗网络中判别器与生成器博弈的机制,从而避免了由于对抗平衡难以掌控而导致的训练不稳定问题,例如模式崩溃。相比依赖判别器来确保生成样本符合数据流形的方式[16],本文基于人类视觉感知设计了骨骼点约束与偏移损失函数,以实现类似的效果。在大量实验验证的支持下,该方法不仅能够保持生成样本的合理性,还展现出优异的训练稳定性。本文的主要贡献可以总结如下:

1. 在生成对抗网络(GAN)相关的任务中,判别器起着判断生成样本是否真实的关键作用,本文提出偏移损失函数与骨骼点约束来替代判别器,使生成的对抗样本保证人眼不可察觉。

2. 实验结果表明,经过训练后的生成器能够在测试集上无需查询即可高效生成对抗样本,并且在攻击效果上表现出色,显著提升了攻击的效率和不可感知性。

1 相关工作

1.1 基于人体骨架的动作识别

人体骨架数据被广泛应用于动作识别[16]。人体骨架动作通常表示为一系列骨架关节点序列,常见的数据集如 NTU-60, NTU-120[18]和 HDM05[37]。这些骨架数据可以通过深度学习模型(如人体姿态估计模型 OpenPose)或传感器设备(如深度相机、惯性测量单元 IMU)获取。提取的骨架信息一般以关节坐标的形式表示,并作为输入供深度学习模型训练。在训练过程中,模型学习如何从骨架数据中捕捉动作的特征与模式。例如,STGCN[19]模型通过对骨架的时空结构进行建模,从而提取相应的时空特征用于动作识别。

1.2 对抗攻击

对抗攻击[19][21][22][23]是一种针对深度学习模型的隐私攻击方法。攻击者在获取目标模型访问权限后,通过大量查询尝试逼近模型的分界。在现有研究中,大多数方法依赖于在分类边界附近利用梯度下降搜索合适的攻击样本,并引入人体运动学约束以确保生成样本符合物理规律。然而,该类方法通常需要数百甚至上千次的梯度下降迭代

才能生成一个对抗样本,计算开销较为昂贵。

基于 GAN 对抗网络的攻击方法[24][25][26]由三个部分组成,生成器,判别器和分类器。生成器接受一个输入,并试图为该输入找到一组合适的扰动,这些扰动可以在随后的迭代中欺骗判别器和分类器。然而通过这种博弈的过程来训练生成器会面临生成器与判别器之间平衡的挑战。

2 方法

本节将全面阐述提出的模型—约束生成器扰动(Constrained Generator Perturbation),简称 CGP。为了更深入地理解该模型,本节将围绕三个核心方面进行详细解析。首先,探讨生成器的设计,重点阐述如何巧妙构建生成器,以高效生成对抗扰动。其次,利用骨骼点约束有效的提升对抗样本的不可感知性,这一策略也是替代判别器的关键之一。最后,介绍偏移损失函数,该部分与骨架点约束相结合,最终取代判别器,实现了无判别器的对抗扰动生成机制。

2.1 生成器模型设计

生成器的核心思想是利用一个预训练模型作为特征提取器,使其能够根据提取到的特征高效生成对抗扰动。经过大量实验对比,本文最终选择 STGCN 作为特征提取器,其主要优势体现在以下两个方面:

第一:相比于 MSG3D 和 AGCN, STGCN 的体积更小,计算速度更快,占用的显存也更少,这为模型提供了更高的效率。

第二:实验结果表明,STGCN 提取的特征在攻击任务中的表现优于 AGCN,能够有效提升对抗攻击的成功率。

完成特征提取后,所提取的特征将被输入至扰动生成器。该扰动生成器由两层反卷积层组成,每层均采用双曲正切函数(tanh)作为激活函数。选用 tanh 函数作为激活函数的原因在于,期望最终生成的扰动幅度尽可能小,从而最小化扰动的不可感知性,以满足相关研究对扰动不可感知性的严格要求。

如图 1 所示,原始数据被送入特征提取器以获得对应的特征表示,提取到的特征再进入扰动生成器以产生扰动,生成的扰动与原始数据叠加后形成攻击样本。扰动的优化由分类损失、骨骼点约束与偏移损失共同作用,以保持结构合理性的同时增强攻击效果。整个过程以迭代方式执行,直到扰动

收敛或达到设定的优化步数。




图1 无判别器生成模型

Figure.1 Discriminator-Free Generative Model

2.2 骨骼点约束设计

在缺乏约束机制的情形下，若直接借助生成器生成扰动，所产生的数据范围极有可能被限定在 $[-1,1]$ 区间内。在过往的相关研究工作中，通常采用clip操作来对扰动范围加以限制[28]。然而，针对骨架数据而言，该方法并不具备适配性。

在各类动作中，不同骨骼点对整体运动所产生的贡献存在显著差异[29]。此外，同一骨骼点在不同动作情境下，即便受到同等程度的扰动，其引发的视觉效果亦不尽相同。以人体骨架为例，结构密集区域的骨架点，相较于位于稀疏区域的骨架点，其受到扰动时更易被视觉感知。这是由于密集区域内的节点间能够相互参照，致使该区域内的骨架点扰动在视觉上较难被察觉[30]。

经对 NTU60 及 NTU120 [18]数据集展开深入剖析，研究发现众多动作与手部活动存在紧密联系。即便是诸如走路、跑步和踢球这类看似主要由腿部执行的动作，手部的辅助作用实则不可或缺。反之，在阅读、喝水、洗脸等以手部为主导的动作过程中，腿部的运动变化相对微弱[31]。基于上述观察，本文提出了针对骨架点的约束设计方案。

如图2(a)所示，图中通过不同颜色对各骨架点的约束权重予以标识。其中，黄色点所表征的约束权重为180，蓝色点对应的约束权重为300，绿色点则代表着高达500的极高约束权重。由图2(a)能够直观且清晰地看出，上半身的若干关键连接点被赋予了相对较大的约束权重，其中蓝色点所对应的权重表现尤为突出。

由于在静止以及运动状态下，这些蓝色点与其

他点或骨架共同构成密集区域。基于此，为规避被人眼所察觉，针对这些点的扰动应控制在尽可能小的范围。特别值得着重关注的是绿色点，该点呈现出极高的敏感性。即便仅对其施加0.002这一微小扰动，亦极易被人眼所捕捉。这是因为该绿色点在任何情形下均与身体中心点维持着紧密连接关系，致使针对它的扰动所引发的影响格外显著。

骨架点约束设计不管在任何阶段都可以进行修改，这样的设计可以让模型在训练完毕以后根据攻击者需要可以自由配置增强或降低不可感知性。相应的越高的不可感知性配置会降低攻击率。综上所述用数学表达可以如下：

$$feature = FeatureExtract(x) \quad (1)$$

$$output = \frac{Deconv_{2-layer}(features)}{cs} \quad (2)$$

$FeatureExtract$ 为特征提取模块， $Deconv_2$ 为反卷积计算， cs 为骨骼点约束数组。

2.3 偏移损失函数

正如前一节所述，引入了骨骼点约束数组的概念，通过该约束，可以将生成的扰动限制在一个预设的经验范围内，从而保持骨架数据的合理性。然而，仅仅遵循这些约束是不够的，因为不仅需要确保生成的样本满足骨架结构的合理性，更希望在这个范围内尽可能地减小扰动的幅度，以实现对抗攻击的不可感知性。

为此，精心设计了一个偏移损失函数。该损失函数的核心目标在于鼓励模型在严格满足骨骼点约束的前提下，生成更加细微的扰动。通过将偏移损失纳入总损失函数中，模型在训练过程中不仅需要考虑如何欺骗分类器，还必须权衡扰动的大小，确保对抗样本在攻击效果和视觉不可感知性之间达到最佳平衡。

$$norm = \frac{\sum_{i=0}^T \left(\sum_{j=0}^V (x_{i,j} - \hat{x}_{i,j}) * weights \right)}{N} \quad (3)$$

x 是原始数据， $\hat{x}$ 是扰动数据， V 是骨架点数量， T 是总帧数， N 是批次大小， $weights$ 是节点权重。为了确保原始数据与扰动数据之间的差异尽可能微小，引入了偏移损失函数。该函数计算每一帧中骨架点在原始数据和扰动数据之间的差距，理想情况下，这个差距应当趋于最小，因为差距越小，意味着扰动的不可感知性越强。根据2.2节中关于骨架

点约束的设计,在偏移损失函数中为某些节点分配了不同的损失权重。如图2(b)所示,对于蓝色节点,赋予了较大的损失权重1.5,而对于黄色节点,则赋予了1的损失权重。这样的权重分配意味着,对于那些被赋予更大权重的节点,其位置偏移将对总损失产生更大的影响,从而激励模型在生成扰动时更加关注这些节点的稳定性。




图2 骨骼点约束与偏移损失函数

Figure 2 Skeleton Point Constraints and Offset Loss Function

3 实验

3.1 实验设置

3.1.1 数据集

实验验证基于广泛采用的 NTU60 和 HDM05[37] 基准数据集完成,NTU60 包含 56,880 条骨架序列,涵盖 60 个动作类别。不同格式的骨架被统一映射为标准的 25 关节结构;HDM05 数据集是用动作捕捉系统捕获的 3D 运动数据库。它包含由 5 名非专业演员执行的 130 个动作的 2337 个序列。每一帧都提供了拍摄对象的 3D 关节位置。

3.1.2 基线模型

考虑 STGCN[15](Yan et al., 2018), AGCN (Shi et al., 2020) [27], MSG3D(Liu et al., 2020) [33], CTR-GCN(Chen et al., 2021) [38]和 HiCo (Dong et al., 2023) [34]。

3.1.3 基线方法

SMART[9], I-FGM[35], ABLA[39]和 TASAR[40]被选择作为对比方法。SMART, ABLA 和 TASAR 是骨架领域的典型攻击方法,而 I-FGM 最初是针对图像领域设计的,但在本研究中已被迁移到骨架领域使用。

3.1.4 实现细节

采用了 STGCN 预训练模型作为特征提取器,以捕捉时空数据中丰富的特征信息。在模型训练过程中使用训练集,学习率被设置为 0.0001,权重衰减系数也选定为 0.0001,以确保模型的稳定性和收敛性,使用 Adam 优化器,并计划执行 500 个训练周期。值得注意的是本文的方法在生成器训练完毕后,可以直接用于其它测试集上快速产生对抗样本,这是其它方法所不具备的。

3.1.5 感知性评估指标

采用 No-Box(Lu et al., 2023) [36]中提出的感知评估指标,综合考量了骨架序列的三个的不可感知性。数学表达式如下:

$$S = \alpha * S_{pos} + \beta * S_{len} + \gamma * S_{acc} \quad (4)$$

$$S_{pos} = \frac{1}{T} \sum_{t=1}^T [(x_t - x'_t) + (y_t - y'_t) + (z_t - z'_t)] \quad (5)$$

$$S_{len} = \frac{1}{N} \sum_{t=1}^N \frac{1}{T} \sum_{t=1}^T (l_{t,i} - l'_{t,i})^2 \quad (6)$$

$$S_{acc} = \frac{1}{T} \sum_{t=2}^{T-1} [(a_{x,t} - a'_{x,t})^2 + (a_{y,t} - a'_{y,t})^2 + (a_{z,t} - a'_{z,t})^2] \quad (7)$$

其中 S 是三个均方误差的加权和, α 、 β 和 γ 是权重系数, T 是序列长度, S_{pos} 是坐标位置的差异, x_t , y_t , z_t 表示在 t 时刻的骨架点坐标, N 是骨节的数量, S_{len} 是骨架长度的差异, $l_{t,i}$ 骨节长度在原始骨架中的长度, S_{acc} 是骨架加速度的差异,骨架加速度可以通过对坐标位置求二阶导数得到。原始骨架在 t 时刻的加速度 a_t ,其中 $a_{x,t} = x_{t+1} - 2x_t + x_{t-1}$ (类似地得到 $a_{y,t}$ 和 $a_{z,t}$ 方向)。通过这一综合评估能更全面地理解扰动对骨架数据的影响程度。

3.1.6 攻击成功率

攻击成功率是评估模型在面对经过扰动正确识别样本时的性能变化指标,专注于计算在添加扰动后,原本能够被模型正确识别的样本中有多少比例发生了分类错误。这一指标并不涉及那些原本就无法被模型识别的样本,而是专门衡量了模型对原本正确识别样本在受到扰动后的误判率增加情况。

3.2 攻击分析

3.2.1 生成式攻击

训练完成后的生成器能够在其他任意数据集上快速生成对抗样本。例如,在 NTU60 和 HDM05 的训练集与测试集上均表现出良好效果,这是传统

对抗算法所不具备的优势。

表 1 的结果表明, 当以 MSG3D 和 AGCN 作为目标模型时, 所提出的生成器能够实现较高的攻击成功率; 然而, 在 STGCN 和 HiCo 上的攻击效果则明显下降。这可能是由于 STGCN 更依赖于全局结构信息, 而生成器生成的扰动更侧重于局部几何结构的破坏, 从而削弱了其攻击效果。对于 HiCo, 由于其无监督特性, 在训练过程中引入了增强样本, 相当于在一定程度上进行了防御训练, 因此攻击成功率的降低也在预料之中。

表 2 的结果进一步表明, 生成器在 NTU60 测试集上依然保持了优异表现。这一现象揭示了一个关键特性: 经过充分训练的生成器具有较强的泛化能力, 能够在测试集上实现稳定而有效的攻击。因此, 借助这一特性, 训练完成的生成器可进一步应用于大规模且高效的对抗性攻击任务。

表 3 的结果表明, 生成器不光在 NTU60 数据集上有着良好的效果, 而且在 HDM05 上仍有着优异表现。HDM05 与 NTU60 在动作类别覆盖、骨架节点标注规范及数据采集环境上存在明显差异, 本文方法能跨越这些差异保持稳定性能, 充分证明其对不同数据分布的适配能力和较强的泛化特性。

表 1 CGP 在 NTU60 训练集上攻击结果。

Table 1 CGP attack results on the NTU60 training set.

数据集	模型	CGP
ntu60_train_xview	MSG3D	71.2
	AGCN	67.4
	STGCN	3.7
	HICO	15.7

表 2 CGP 在 NTU60 测试集上攻击结果。

Table 2 CGP attack results on the NTU60 test set.

数据集	模型	CGP
ntu60_val_xview	MSG3D	67.7
	AGCN	51.9
	STGCN	3.5
	HICO	11.7

表 3 CGP 在 HDM05 测试集上攻击结果。

Table 3 CGP attack results on the HDM05 test set.

数据集	模型	CGP
hdm05	CTRGCN	96.4
	AGCN	87.31
	STGCN	10.6

表 4 CGP 在 HDM05 上迭代优化攻击结果。

Table 4 Iterative Optimization Attack by CGP on HDM05.

数据集	模型	CGP
hdm05	CTRGCN	94.64
	AGCN	93.65
	STGCN	86.45

3.2.2 迭代优化攻击

CGP 采用逐轮迭代的方式对生成器进行优化以产生扰动, 这种精细化的迭代模式能够针对生成器每一轮输出的扰动进行精准修正, 从而使得扰动生成过程更加具有针对性。如表 4 所示, CGP 在迭代优化条件下的效果相比表 3 有所提升, 这是由于迭代优化本身属于相对简单的攻击场景。如表 6 所示, CGP 在攻击成功率方面的表现低于对比 SMART, I-FGM, TASAR, 但这一结果是符合预期的。因为 CGP 的核心设计理念在于其生成式架构, 其主要优势并不体现在迭代优化上, 而是在于模型一旦训练完成, 便能够无需任何额外迭代步骤即可迅速生成高质量对抗样本, 从而在推理阶段显著提升生成效率。尤其在处理规模庞大的人体动作骨架数据时, 这种“一次训练, 多次生成”的机制能够大幅降低时间与计算成本, 更好地满足高实时性任务的处理需求。

3.2.3 计算效率

从训练角度来看, 无判别器架构避免了生成器与判别器的对抗博弈过程(传统 GAN 需同时优化两个网络的参数), 这减少了模型的参数量以及简化了训练的计算过程。

从计算开销来看, 本文方法中的生成器仅需一步推理即可完成样本生成, 而 SMART 方法通常需要超过 100 次迭代。以 NTU60 数据集上的 STGCN 模型为例, CGP 在生成一个批次样本时耗时不足 1 秒, 而 SMART 则需要约 21 秒, 大规模任务中时间优势更突出。

3.2.4 可转移性评估

在 NTU RGB+D 60 训练集上使用 AGCN 作为代理模型，以评估其对受害者模型的攻击效果。NTU RGB+D 60 数据集不仅包含 60 类动作，还提供了 RGB、深度、骨骼等多模态数据，此次实验聚焦骨骼数据，能更精准检验骨架对抗攻击的跨模型迁移能力。具体而言，在 NTU RGB+D 60 的训练集和测试集上分别针对 MSG3D 和 STGCN 进行了攻击性测试，测试保持输入、预处理方式与原模型一致。表 7 展示了相应的结果。无论在哪一个数据集上，AGCN 对 MSG3D 都表现出了较高的可转移性，训练集转移率 18.3%、测试集 16.4%；而对 STGCN 转移率极低，因 STGCN 全局建模强、对局部扰动不敏感。

表 5 STGCN 在 NTU60 上的对抗样本感知性评估。

Table 5 Perceptual evaluation of adversarial samples for STGCN on NTU60.

方法/模型	感知性
SMART	0.1950
ours(CGP)	0.1145

3.2.5 样本的感知性

表 5 呈现了基于 No-Box 体系构建的量化指标，

该指标综合考量了骨骼点坐标、骨骼长度及加速度差异等关键参数，可全面表征扰动的感知性与攻击有效性。将本文所提方法与 SMART 方法进行对比可知，所提方法在感知性指标上实现了 41.28% 的提升，具体数值从 0.1950 降至 0.1145，表明人类对扰动差异的察觉难度显著提升。

此外，3.2.6 节进一步阐述了 CGP 的另一关键优势：训练完成后的生成器，其感知性约束具备可调节性，且该调节过程无需额外计算开销，无需重新训练模型即可快速生效。该特性为所提方法赋予了极高的灵活性，使其能够根据不同应用需求灵活权衡性能——既可以优先追求更高的攻击成功率，也可以侧重强化扰动的感知性。

3.2.6 不同骨骼点约束配置

表 8 进一步量化了不同约束配置的具体表现，以 A/B 两组为例，B 组感知性由 0.6824 增至 1.7020，攻击率由 75.9% 上升到 77.2%，而 A/B 两组的约束权重差异可通过表 9、表 10 清晰查看；在 C/D 组中，通过对第 21 号关节施加更强约束（具体权重配置见表 11、表 12），实现了对攻击策略的精细调整，使该方法在不同场景下均能取得更好的攻击效果。

表 6 在 NTU60 上迭代优化攻击结果。

Table 6 Iterative Optimization Attack on NTU60.

模型	数据集	CGP	SMART	I-FGM	ABLA	TASAR
MSG3D	ntu60_train_xview	87.5	99.67	100	46.15	99.61
AGCN	ntu60_train_xview	96.9	100	99.95	35	99.87
STGCN	ntu60_train_xview	34.4	100	99.91	80.83	99.29
HICO	ntu60_train_xview	100	100	100	39.21	100

表 7 在 NTU60 上可转移攻击，代理模型为 AGCN。

Table 7 Transferable Attacks on NTU60, Surrogate model is AGCN.

数据集	模型	代理模型	转移率
ntu60_train_xview	MSG3D	AGCN	18.3
	STGCN	AGCN	0.1
ntu60_val_xview	MSG3D	AGCN	16.4
	STGCN	AGCN	0.5

表 8 STGCN 在 NTU60 上不同骨骼点约束下的攻击表现。感知性与攻击率是成正相关的。

Table8 Attack performance of STGCN under different joint-constraint settings on NTU60. Perceptual quality and attack success rate are positively correlated.

数据集	骨骼点约束配置	感知性	攻击率
ntu60_train_xview	A	0.6824	75.9
	B	1.7020	77.2
	C	0.1011	23.2
	D	0.1624	57.8

3.2.7 对抗样本可视化


图 3 展示了“喝水”和“刷牙”两类动作在原始骨架与扰动后骨架下的对比结果，所选样本均来自 NTU60 测试集。可以看出，无判别生成器的扰动在视觉上几乎难以察觉，“喝水”时手臂轨迹、“刷牙”时手部运动均与原始高度重合，关键特征保留度高。整体动作轮廓、关节之间的相对位置关系等关键信息几乎未受到影响。这表明该方法能够在不改变动作本质特征的前提下，实现对骨架的有效扰动。图 4 选取了扰

动较大的几帧，并将对抗样本与原始样本叠加在一起以便看出它们之间的差异。


表 9 骨骼点约束配置 A。

Table 9 Skeleton Point Constraint Configuration A.

骨骼点序号	约束权重
1,5,6,7,8,9,10,11,12,13,14,15 ,16,17,18,19,20,21,22,23,24,25	50
2,4	300
3	500



(a) 喝水动作可视化



(b) 刷牙动作可视化

图 3 对抗样本可视化（第一行为原始样本，第二行为扰动样本）。可以明显观察到生成的对抗样本与原始样本外观几乎无差异。

Figure.3 Visualization of Adversarial examples (first row shows the original samples, and the second row shows the perturbed sample). It is evident that the generated adversarial samples are nearly indistinguishable from the original ones in appearance.




图 4 扰动差异可视化(第一行动作是喝水, 第二行动作是刷牙)。可以明显观察到手部动作出现了细微的偏移。

Figure.4 Visualization of Perturbation Differences (first action is drinking water, and second action is brushing teeth). It can be clearly observed that there is a slight deviation in the hand movements.

表 10 骨骼点约束配置 B。

Table 10 Skeleton Point Constraint Configuration B.

骨骼点序号	约束权重
1,5,6,7,8,9,10,11,12,13,14,15 ,16,17,18,19,20,21,22,23,24,25	20
2,4	100
3	200

表 11 骨骼点约束配置 C。

Table 11 Skeleton Point Constraint Configuration C.

骨骼点序号	约束权重
1,5,9,13,14,15,16,17 ,18,19,20	300
2,4,6,7,8,10,11,12,21 ,22,23,24,25	500
3	800

表 12 骨骼点约束配置 D。

Table 12 Skeleton Point Constraint Configuration D.

骨骼点序号	约束权重
1,5,6,12,13,14,15,16 ,17,18,19,20	200
2,4,6,7,8,10,11,12,21 ,22,23,24,25	300
3	800

4 结论

本文提出了一种面向骨架动作识别的生成式攻击方法,通过合理设计生成器结构,并引入骨骼点约束和偏移损失以替代判别器,从而有效缓解对抗博弈中的平衡问题。同时,与迭代优化策略相比所生成的样本在不可感知性方面具有显著优势。此外,训练完成后无需重新训练模型,便可根据任务需求灵活调整约束配置,生成更具攻击性或更高隐蔽性的对抗样本,以支持防御训练和模型鲁棒性测试等应用场景。

局限性:目前的骨架约束权重是根据骨架运动的先验以及大量实验确定的,未来工作中将进一步研究如何结合自适应约束权重来提高算法性能。

参考文献 (References)

- [1] PREKSHA P, ANKIT T, et al. A survey on video-based Human Action Recognition: recent updates, datasets, challenges, and applications[J]. Artificial Intelligence Review: An International Science and Engineering Journal,2020,54: 2259-2322.
- [2] ZHANG Y, WANG X, LI Q. Spatial Temporal Graph Autoencoder Network for Skeleton-Based Human Action Recognition [J]. MDPI, 2024, 5 (3): 83.
- [3] WANG B, YAO Y S, SHAN S, et al. Neural cleanse: Identifying and mitigating backdoor attacks in neural networks[C]//2019 IEEE Symposium on Security and Privacy (SP). 2019: 707-723.
- [4] SHEN S, CHEN X, YUAN H, et al. Adversarial Driving: Attacking End-to-End Autonomous Driving[C]//Proceedings of the IEEE/CVF

- Conference on Computer Vision and Pattern Recognition. Nashville, USA, 2021: 12091-12100.
- [5] PAYA A, ARRONI S, GARCÍA-DÍAZ V, et al. Apollon: A robust defense system against Adversarial Machine Learning attacks in Intrusion Detection Systems[J]. *Computers & Security*, 2024, 136: 103546.
 - [6] AKHTAR N, MIAN A, KARDAN N, et al. Advances in adversarial attacks and defenses in computer vision: A survey[J]. *IEEE Access*, 2021, 9: 155161-155196.
 - [7] ZHU Y F, ZHAO Y C, HU Z H, et al. A review of black-box adversarial attacks on image classification[J]. *Neurocomputing*, 2024, 610: 128512.
 - [8] MADRY A, MAHTAB S, PAPERNOT N, et al. Towards deep learning models resistant to adversarial attacks[C]//*International Conference on Learning Representations*. Toulon, France, 2018.
 - [9] ZHANG C Y, HU M W, LI W H, et al. Adversarial attacks and defenses on text-to-image diffusion models: A survey[J]. *Information Fusion*, 2025, 114: 102701.
 - [10] ALMASHHADI S, ALOTAIBI S, ALGHAMDI A, et al. Modeling Realistic Adversarial Attacks against Network Intrusion Detection Systems[C]//*Proceedings of the IEEE International Conference on Cyber Security and Cloud Computing*. New York, USA, 2022: 234-241.
 - [11] ZHOU X, ZHANG T, LO D. Large Language Model for Vulnerability Detection: Emerging Results and Future Directions[C]//*Proceedings of the 2024 ACM/IEEE 44th International Conference on Software Engineering: New Ideas and Emerging Results (ICSE-NIER'24)*. 2024: 47-51.
 - [12] DIAO Y, SHAO T, YANG Y L, et al. BASAR: black-box attack on skeletal action recognition[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021: 7597-7607.
 - [13] WANG H, HE F, PENG Z, et al. Smart: Skeletal motion action recognition attack[C]//*IEEE Conference on Computer Vision and Pattern Recognition*. Long Beach, USA, 2019: 1911.07107.
 - [14] LIU J, AKHTAR N, MIAN A. Adversarial attack on skeleton-based human action recognition[J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2020, 33(4): 1609-1622.
 - [15] LI Q W, KAILKHURA B, ANIRUDH R, et al. MR-GAN: Manifold Regularized Generative Adversarial Networks for Scientific Data. *{SIAM} J. Math. Data Sci*, 2021, 3(4): 1197-1222.
 - [16] XIAO C, LI B, ZHU J Y, et al. Generating adversarial examples with adversarial networks[C]//*International Joint Conference on Artificial Intelligence*. Stockholm, Sweden, 2018: 1801.02610.
 - [17] HAODONG D, YUE Z, KAI C, et al. Revisiting Skeleton-Based Action Recognition[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR)*, 2022: 2969-2978.
 - [18] AMIR S, JUN L, TIAN-TSONG N, et al. Ntu rgb+d. A large scale dataset for 3d human activity analysis[C]//*Proceedings of the IEEE conference on computer vision and pattern recognition*. Las Vegas, USA, 2016: 1010-1019.
 - [19] YAN S, XIONG Y, LIN D. Spatial temporal graph convolutional networks for skeleton-based action recognition[C]//*Proceedings of the AAAI conference on artificial intelligence*. City of New Orleans, USA, 2018: 7444-7452.
 - [20] WANG H, HE F, PENG Z, et al. Understanding the robustness of skeleton-based action recognition under adversarial attack[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021: 14656-14665.
 - [21] LIU J, ZHOU J, ZENG J, et al. Difattack: Query-efficient black-box adversarial attack via disentangled feature space[C]//*Proceedings of the AAAI Conference on Artificial Intelligence*, 2024: 3666-3674.
 - [22] PARK J, MILLER P, MCLAUGHLIN N. Hard-label based small query black-box adversarial attack[C]//*Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, 2024: 3986-3995.
 - [23] GUO C, GARDNER J, YOU Y, et al. Simple black-box adversarial attacks[C]//*International conference on machine learning*, 2019: 2484-2493.
 - [24] JINYIN C, HAIBIN Z, HUI X, et al. MAG-GAN: Massive attack generator via GAN[J]. *Information Sciences*, 2020, 536: 67-90.
 - [25] WANG D, XUEMENG W, JINLONG F. IDS-GAN: adversarial attack against intrusion detection based on generative adversarial networks[C]//*2024 5th International Conference on Computer Vision, Image and Deep Learning(CVIDL)*. IEEE, 2024: 1130-1134.
 - [26] SUN H, WANG S M, MA L J. Adversarial attacks on GAN-based image fusion[J]. *Information Fusion*, 2024, 108: 102389.
 - [27] LEI S, YIFAN Z, JIAN C, HANGING L. Two-Stream Adaptive Graph Convolutional Networks for Skeleton-Based Action Recognition[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2019: 12026-12035.
 - [28] LIU Z H, PENG W Y, ZHOU J, et al. MI-FGSM on Faster R-CNN Object Detector[C]//*Proceedings of the 2020 4th International Conference on Video and Image Processing (ICVIP'20)*. 2021: 27-32.
 - [29] YENDURI S, CHALAVADI V, MOHAN C K. STIP-GCN: Space-time interest points graph convolutional network for action recognition[C]//*2022 International Joint Conference on Neural Networks (IJCNN)*. 2022: 1-8.

- [30] TANG T, LANDIS W, RAGUIN E, et al. A 3D Network of Nanochannels for Possible Ion and Molecule Transit in Mineralizing Bone and Cartilage[J]. *Advanced NanoBiomed Research*, 2022, 2(8): 2100162.
- [31] GORDON E M, CHAUVIN R J, VAN A N, et al. A somato-cognitive action network alternates with effector regions in motor cortex[J]. *Nature*, 2023, 617(7960): 351-359.
- [32] SHI L, ZHANG Y, CHENG J, et al. Two-stream adaptive graph convolutional networks for skeleton-based action recognition[C]//*Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. Long Beach, USA, 2019: 12026-12035.
- [33] LIU Z, ZHANG H, CHEN Z, et al. Disentangling and unifying graph convolutions for skeleton-based action recognition[C]//*Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. City of Seattle, USA, 2020: 143-152.
- [34] DONG J, SUN S, LIU Z, et al. Hierarchical contrast for unsupervised skeleton-based action representation learning[C]//*Proceedings of the AAAI Conference on Artificial Intelligence*. Washington, USA, 2023: 525-533.
- [35] SANTOS E, SANTOS E, NGUYEN H, et al. I-FGM - Information retrieval in highly dynamic search spaces[C]//*Intelligent Computing: Theory and Applications IV*. SPIE, 2006, 6229: 622901.
- [36] LU Z, WANG H, CHANG Z, et al. Hard No-Box Adversarial Attack on Skeleton-Based Human Action Recognition with Skeleton-Motion-Informed Gradient[C]//*Proceedings of the IEEE/CVF International Conference on Computer Vision*. Vancouver, Canada, 2023: 4597-4606.
- [37] Muller, "M.", Roder, T., Clausen, M., Eberhardt, B., Kruger, "B.", Weber, A.: Documentation mocap database hdm05. Tech. Rep. CG-2007-2, Universität at Bonn (June 2007)
- [38] Yuxin Chen, Ziqi Zhang, Chunfeng Yuan, Bing Li, Ying Deng, and Weiming Hu. Channel-wise topology refinement graph convolution for skeleton-based action recognition. In *Proceedings of the IEEE/CVF international conference on computer vision*, pp. 13359-13368, 2021. 3, 4, 8, 20
- [39] Tanaka, N., Kera, H., Kawamoto, K.: Adversarial bone length attack on action recognition. In: *Thirty-Sixth AAAI Conference on Artificial Intelligence, AAAI 2022, Thirty-Fourth Conference on Innovative Applications of Artificial Intelligence, IAAI 2022, The Twelveth Symposium on Educational Advances in Artificial Intelligence, AAAI-SAR: model agnostic adversarial contrastive learning for robust skeleton-based action recognition* 2509 *ligence, EAAI 2022 Virtual Event, February 22- March 1, 2022, AAAIPress, 2022*, pp. 2335-2343.
- [40] DIAO Y F, WU B Q, ZHANG R X, et al. TASAR: TRANSFER-BASED ATTACK ON SKELETAL ACTION RECOGNITION [C]//*International Conference on Learning Representations (ICLR)*. 2025.

Generative Adversarial Attacks for Skeleton-based Action Recognition

WU Zhize^{1,2}, ZOU Huanxin¹, LU Menghao¹, HUA Shancong¹, LI Teng³, WANG Xiaofeng^{1,*}

(1. School of Artificial Intelligence and Big Data, Hefei University, Hefei 230601, China; 2. State Key Laboratory of Opto-Electronic Information Acquisition and Protection Technology, Anhui University, Hefei 230601, China; 3. School of Artificial Intelligence, Anhui University, Hefei 230601, China)

Abstract: Human skeleton action recognition technology is facing potential security risks. Existing research primarily relies on adversarial algorithms to generate adversarial samples for evaluating model robustness. However, such methods typically involve high computational costs, making it challenging to efficiently generate large-scale, high-quality adversarial samples. In contrast, generator-based attack methods can quickly and efficiently produce adversarial samples after training, offering greater practicality. Nonetheless, most generators for skeleton adversarial attacks rely on adversarial networks for training, and the convergence issues associated with adversarial networks have long been a challenge, limiting their practicality and stability. To address this, we propose a discriminator-free generative skeleton adversarial attack method, which omits the discriminator component of the adversarial network to generate adversarial samples with enhanced concealment. This method incorporates skeleton manifold constraints and an offset loss function to ensure that the generated adversarial samples align with human motion patterns while retaining adversarial properties. Experimental results demonstrate that this method achieves outstanding attack performance across various pre-trained models, maintaining high imperceptibility in perceptual evaluations. Compared to existing adversarial attack methods, it exhibits clear advantages in attack success rate, computational efficiency, and imperceptibility, providing a novel and effective approach to enhancing the security of skeleton action recognition systems.

Keywords: Adversarial example; Discriminator free generator; Human skeleton point constraint; Offset loss function; Generative adversarial attack

Received: 2025-09-25; **Accepted:** 2025-12-19;

Foundation item: National Natural Science Foundation of China (62406095); Natural Science Foundation of Anhui Province (2308085MF213); University Scientific Research Innovation Team Project of Anhui Province (2022AH010095, 2024AH010030); Hefei Key Technology R&D “Champion-Based Selection” (2023SGJ011)

***Corresponding author:** E-mail: xfwang@hfu.edu.cn